AI 模型构建

生态地图：谁在推动，资源怎样流转

从参与方到成果，再到协作链与成本分摊

参与者 · 成果与资源 · 协作链 · 成本分摊 · 信息入口 · 边界

01 / PARTICIPANTS

谁提出、实现与维护

02 / RESOURCES

哪些成果可以被复用

03 / PIPELINE

一个模型怎样变成助手

04 / COST

钱和资源落在谁身上

05 / CHANNELS

从哪里持续拿到可靠信息

06 / BOUNDARY

哪些还没核实

> 生态不是一串名单。
> 它是一条链上，谁做了什么、谁付了钱、哪一环最容易断。

00 / 先读这一页：生态地图到底在看什么

领域地图回答“这个领域有什么、怎么工作”，生态地图回答的是另一半：**这些成果是谁做出来的，靠什么流转，成本落在谁身上。**所以它不列排行榜，只画关系。

打个比方：把它想成你家楼下的菜市场

菜市场里同时有五拨人：**种菜的**（研究团队，产出原始方法）、**批发商**（平台，把货运到你能拿到的地方）、**摊主**（工具与社区，把菜收拾成能下锅的样子）、**买菜的**（我们，拿来用）、**市场管理员**（规则与许可，决定谁能卖什么）。

这个比方的好处是：它一眼能看出**“谁付钱”和“谁干活”不是同一批人。**种菜的人不负责摊位租金，批发商也不负责你今晚做什么菜。生态地图要画的，正是这条分工线。

但比方也有边界：菜市场的货是实物，模型不是。模型可以被无限复制，边际成本接近零，所以**“免费下载”和“零成本”是两件事**——后面的成本分摊一节会专门讲这一点。



图 1　生态地图骨架：四类参与者、四类成果、两条关系

来源：作者绘制；节点与关系整理自《生态地图素材包》（L4）。

读这张地图的三条规矩

1. **只画关系，不排名。**说“某团队发布了某个模型”是一句事实；说“某团队最强”是一句判断，本册不写后者。
2. **事实和推断分开标。**凡是本组自己推出来的（比如“成本主要落在推理这一步”），都标成推断，不混进事实里。
3. **版本和日期随身带。**生态是会变的，一条“vLLM 9.55 万星”离开日期就没有意义。本册所有数字都带核对日期。

> 一句话记住
>
> 生态地图不看谁最强，看的是**一条链上谁做了什么、谁付了钱、哪一环容易断。**把这三件事说清楚，比罗列一百个仓库有用。

01 / 参与者：四类人，四种贡献

生态按“模型 → 分发 → 适配 → 评测 → 推理 → 应用”组织。这一节只回答一件事：**这条链上每一环是谁在做**。写的是入选理由和代表贡献，不是综合排名。

1.1 研究团队：从原始工作找到方法的来处

对象	代表贡献	入选理由（为什么是它）	依据
Vaswani 等 Transformer 作者	Attention Is All You Need（2017）	提出影响后续几乎所有语言模型的注意力架构。要看懂基座里“序列信息怎么交互”，只能从这篇起	S01
Patrick Lewis 等 RAG 作者	RAG（2020）	第一次把“检索到的外部知识”和“生成”接在一起，是课程助手要给出处这条思路的来源	S02
Edward J. Hu 等 LoRA 作者	LoRA（2021）	冻结基座、只训低秩适配器。它决定了“学生队也能微调”这件事在资源上是否成立	S03
Tim Dettmers 等 QLoRA 作者	QLoRA（2023）	把量化和适配结合，进一步压低显存门槛。判断“我们这台机器能不能跑”时要回到它	S04
Stanford CS336 课程团队	从数据到模型的开源课程	把“数据 → 训练 → 评测”组织成可自学的路径，是课程之外唯一能对上本组任务的系统材料	S12

边界：这里标识的是论文作者与课程团队身份，**不推断作者当前任职机构，也不虚构实验室归属**。代表实验室入口（如 Stanford NLP）本次抓取超时，暂不建立已核实的贡献关系。

1.2 企业模型团队：谁发布可复用的基座

团队	公开仓库	情况与代表成果	本册定位
阿里 Qwen QwenLM	60	最近推送包括 Qwen3.8、Qwen3.8-Flash-Next、Qwen3-TTS、Qwen-Image-2.1、Qwen-Drive-1.0；Ollama 库已收录 Qwen3.8	主案例
智谱 zai-org	53	GLM-5 7390 星，最后推送 2026-10-15，简介为 From Vibe Coding to Agentic Engineering	候选
DeepSeek deepseek-ai	45	分两类：模型仓库（DeepSeek-V3 10.46 万星、R1 9.2 万星）与基础设施（DeepEP、DeepGEMM、FlashMLA）；模型仓库体积约 1.7 MB，是说明与推理代码，权重另在模型社区发布	候选
月之暗面 MoonshotAI	42	含 Kimi-K3、Kimi-K2.5，以及 kimi-cli、kimi-code 等命令行工具	候选
Meta meta-llama	12	llama 5.96 万星；llama-models 7710 星，最近 release 为 v0.2.0（2025-04-05）	候选

仓库数为 2026-10-25 通过 GitHub API 核对的公开仓库总数。DeepSeek 那个“1.7 MB”很说明问题：**它提醒我们，一个模型的名字、说明、推理代码和权重是四样不同的东西**，下载到的常常只是前两样。

参与者（续）：社区与平台

上一页是“出方法的人”和“出模型的人”。这一页是另外两类：**把方法变成能跑的代码的人**，和**把成果运到你能拿到的地方的人**。少了这两类，前面两类的东西一步也用不上。

1.3 社区与平台：谁维护可复用工具、让成果被分发

对象	类型	贡献与入选理由	依据
Hugging Face 与贡献者	社区 · 平台	同时是分发平台和工具作者：Transformers、PEFT、TRL 都从这里出来。它把“模型加载与训练方法”变成了能跑通的代码	S05–S07
EleutherAI	开源社区	维护 lm-evaluation-harness。评测能复现，靠的是有人把任务配置固定下来	S09
vLLM / Ollama llama.cpp 为延伸	推理工具	把权重变成“能发请求的服务”。三者代表三种资源取舍：吞吐、易用、纯 CPU	S10
魔搭 / Hugging Face	分发平台	提供权重、模型卡与版本入口。国内可访问性与国际渠道不同，这直接影响实验能不能开始	L4
百炼 / 硅基流动	API 平台	托管推理，让只能用 CPU 的网站也能调模型；同时把“成本”从显存换成了账单	S21
Dify / Open WebUI	应用工具	展示模型接口怎样进入一个真正有人用的界面	L4

> 这一节的取舍
>
> 四类里只有 **Qwen 做了主案例**：它有明确的官方发布、权重、Ollama 条目和 API 三条路径，能把整条链走完。其余四家保留为候选，**因为选定比较任务之前，写谁更强都是空话。**

1.4 谁没有写进来，为什么

一份名单的价值，一半来自写了谁，另一半来自**没写谁以及为什么。**下面这四类都真实存在于生态里，本册暂时不列成节点：

没写进来	原因
算力提供商 显卡厂商、云厂商	它们确实决定成本和可获得性，但与本组“课程答疑助手”这个任务之间隔了至少两层，写进来会把关系画得很虚。留到成本分摊一节作背景提一句
榜单与媒体站 LMArena 等	本次抓取未连通，且其排名口径与本册“只看关系”的写法冲突。评测口径放在第 5 页和认知地图的案例②里讨论
数据集原始提供方	多数模型的训练数据未完全公开，硬写会变成猜测。只在“复用权重 ≠ 拥有数据”这一条上提示边界
同类开源框架的其余候选 SGLang、DeepSpeed 等	它们在同一段里承担相似角色，逐个列出会让图变成清单。保留在素材包的完整表里，本册只留每段一个代表

判断标准只有一条：**这个对象和“把模型变成一个能用的课程助手”之间，能不能用一句话说清关系。**说不清就先不进图。

02 / 成果与资源：什么能被复用

生态里的“成果”不是抽象概念，是四类看得见、下得着的东西。这一节对每一类都回答三问：**为什么入选、怎么用、不能推出什么**。第三问最容易被跳过，也最容易出错。



图 2　四类成果与它们的复用方式

来源：作者绘制；分类依据《三张活地图》作业要求 4.1 节。

2.1　论文：方法的出处，不是效果的保证

论文	年份	为什么入选 / 怎么用	不能推出什么
Attention Is All You Need	2017	理解基座结构的第一入口。读的时候要连着问题背景、实验设置、局限一起读	不能说明今天每个模型的内部结构；后续模型各写各的
RAG	2020	把检索与生成接起来的原始工作，是“回答要给出处”的方法来源	本组借的是思路，不是复现它的全部训练设计
LoRA	2021	低秩适配，决定“小资源能不能微调”这件事成立与否	不保证在所有任务上优于全参微调，效果仍要自己测
QLoRA	2023	量化 + 适配，把显存门槛再压一档	论文里的显存数字不能直接当成本组设备的保证

2.2　工具与框架：把方法变成能跑的流程

工具	版本 · 日期	星数	在链上的位置与使用边界
Transformers	v5.20.2 · 10-19	16.8 万	加载与推理的统一入口；本组实际运行过。**版本变了接口也会变**，脚本必须锁版本
PEFT	v0.21.2 · 10-01	2.18 万	实现 LoRA 等参数高效适配；只读过文档，未实际训练
TRL	v1.16.0 · 10-15	1.96 万	组织监督微调等训练流程；数据格式随版本变，需按版本文档准备
LLaMA-Factory	2026-10-21	7.57 万	把微调流程做成可视化操作，适合快速试；**方便不等于可解释**

星数与版本均为 2026-10-25 通过 GitHub API 核对。星数只说明关注度，**不能说明对本组任务适配得好。**

02 / # 成果与资源（续）：工具、数据与评测

接着上一页的工具表。下面这四项都在“把权重变成能用的服务”这一段上，**它们的差异不在先进程度，而在资源取舍**：要吞吐、要易用，还是要一块普通笔记本就能跑。

2.2 工具与框架（续）

工具	版本 · 日期	星数	在链上的位置与使用边界
vLLM	v0.32.0 · 10-18	9.55 万	高吞吐推理部署；需要 GPU，本组只看文档未部署
Ollama	v0.40.11 · 10-24	18.5 万	一条命令拉起量化模型，本组实际运行过；**适合演示，不适合压测**
llama.cpp	v0.7.0 · 10-15	13.2 万	纯 CPU 也能跑，是“没有显卡”时的延伸候选
lm-evaluation-harness	v0.4.13 · 08-31	1.43 万	固定任务配置、记录可比较的结果；框架不等于题库

2.3 数据与评测资源：题库和框架是两样东西

资源	规模 / 日期	用途与边界
C-Eval	1878 星	中文学科题评测集（hkust-nlp/ceval）。可做候选模型初筛，**不覆盖解释、引用和教学体验**
OpenCompass	7545 星	评测平台与榜单，站点 0.1 秒可达；榜单名次受评测设置影响

最容易搞混的一处

“我下载了 lm-evaluation-harness”和“我有一份能测课程答疑的题库”是两件完全不同的事。前者是**跑评测的工具**，后者是**评测的内容**。作业要求里“小组需建设独立测试”指的是后者，目前**这一项仍是空白**。

2.4 把这几样东西拼成一个最小可用方案

资源清单最容易变成“收藏夹”——存了一堆，用的时候还是不知道从哪开始。给一条最小路径，四步，每一步只说一件必须做的事：

MINIMUM PATH / 四步

① **取权重** 从模型卡页面拿带 revision 的下载地址，别用默认分支

② **试加载** 先用 Ollama 一条命令跑起来，确认机器带得动，再谈微调

③ **定口径** 写下评测要用的任务、指标和失败标准，再开始测

④ **留记录** 版本号、设备、耗时各记一行，否则结果无法复现

这四步的价值在于**顺序**：先确认能不能跑，再决定要不要投时间。反过来做（先定评测再发现跑不动）是最常见的浪费。

03 / 关系一：一个模型怎样变成课程助手

这是本书的核心一张图。**模型发布只是起点**，从“有人开源了权重”到“同学打开网页能问问题”，中间至少还有五段路，每一段都可能断掉。



图 3　从开源权重到课程助手的七段协作链

来源：作者绘制；段划分综合《生态地图_素材包_赵志钰》（L4）与各项目官方文档。

3.1　每一段具体在交接什么

下面这一段是本书最能体现“用心”的地方：**不是把七段念一遍，而是说清每段交给下一段的到底是什么东西。**交接物说不清，链子就是断的。

环节	交给下一段的东西	交接不清会怎样
01 发布	权重文件 + 模型卡（许可、上下文长度、训练数据说明）	不知道该不该用、能不能商用，后面全白做
02 分发	带 revision 的可复现下载入口	“上周还能跑”变成“这周报错”，因为默认分支被覆盖了
03 适配	能加载的代码 + 量化/微调配置	显存够不够、模板对不对，全靠试错，时间成本不可控
04 评测	固定任务集 + 运行设置 + 失败案例	只报一个分数，下次换设置就不可比，等于没测
05 推理	稳定接口 + 时延与并发表现	演示时能答，三个人同时问就卡住
06 应用	回答 + 引用出处 + 拒答策略	答案看起来对，但回不到原文，变成“不可核实的回答”
07 反馈	真实问题与错误记录	没有反馈就只能改界面，改不到内容

一句话记住

这条链上**只有第 1 段是别人替我们做好的**，其余六段都要有人接。本组目前的真实状态是：1、2 段借用了公开成果，3、5 段只跑通过一次，4、6、7 段还没真正建起来。

03 / 这条链容易断在五个地方

同一条链，卡点往往不在最难的技术上，而在**最不值一提的手续和口径**上。下面五处，都是本组在整理素材时真实撞到或明确意识到的。

卡点一：以为下载到了模型，其实只拿到说明书

DeepSeek 的模型仓库体积只有约 **1.7 MB**——那里面是说明与推理代码，权重放在模型社区另外发布。第一次接触的人很容易 clone 下来就以为拿到了模型。

怎么破：看仓库里有没有权重文件（.safetensors / .gguf / .bin）。没有就是“说明仓库”，要顺着模型卡去找权重。

卡点二：版本一换，昨天能跑的脚本今天就报错

Transformers 已到 v5.20.2，大版本演进中接口会变；TRL 的数据格式也随版本调整。本组踩过的最典型一次，是同一个加载函数在两种版本里参数名不同。

怎么破：脚本顶部写死版本号，记录 **revision** 而不只是仓库名。“Qwen 某个模型”不是一个可复现的描述，“某仓库某 revision”才是。

卡点三：论文里能跑，我们机器上跑不动

QLoRA 的显存数字是在特定模型、特定设置、特定设备上得到的。把那个数字直接当成“我们这台笔记本也能跑”，是最常见的一次误读。

怎么破：读资源结论时把三件事一起抄下来：**模型规模、量化方式、设备型号**。缺一项，这个结论就不能搬到自己的机器上。

卡点四：分数很高，但不会答课程问题

C-Eval、MMLU 这类通用题库测的是学科知识选择题。课程答疑要的是：解释得让人听懂、说得出出处、不知道时敢说不知道。这三件事**没有一项在通用榜单里**。

怎么破：通用榜单只用来初筛，真正判断要靠自建的小测试集，哪怕只有二十道题，只要每道题都写明“预期答案长什么样”。

卡点五：网络这一步过不去，后面全停

2026-10-25 那次观测里，Hugging Face 请求 10.5 秒超时，魔搭首页 0.2–0.4 秒可达，hf-mirror 约 4.3 秒——同一天、同一台机器，三个入口三种结果。**怎么破：**准备两条下载路线，并在记录里写清用的哪条。别人复现不了，常常不是方法错，是入口不同。

卡点	典型表现	根子上的原因	本组的处理
交接物	clone 完发现没有权重	说明仓库与权重仓库分离	先看文件类型，再顺着模型卡找权重
版本	接口名对不上	库在大版本演进期	锁版本 + 记 revision
资源	显存不够	论文条件与本机不同	三件事一起记，不照抄结论
口径	榜单高但答不好	测的能力不是要用的能力	自建小测试集，写清预期
网络	下载卡住	渠道可达性不同	双渠道，记录用的哪条

> 这五条的共性
>
> 它们都不是“技术不够强”，而是**信息在交接时丢了**：丢了权重、丢了版本、丢了设备条件、丢了任务口径、丢了下载渠道。生态地图画关系，本质上就是在盯这些交接点。

04 / 关系二：钱和资源落在谁身上

第二个关系回答的是经济逻辑：**训练一次很贵，但为什么我们用起来几乎不花钱？**答案是成本被分段承担了，而且承担的人和使用的人不是同一批。



图 4　成本在生态链上的分布

来源：作者绘制；环节划分依据《生态地图_素材包_赵志钰》（L4）与作业要求 4.2 节。

4.1　逐个环节看“谁承担、谁能推出什么”

环节	谁承担资源	在本组项目中的表现	不能据此推出
预训练	模型机构与算力提供方	本组不复现，直接复用已有模型或 API	没有公开账单，就不能写“单次训练必为多少美元”
权重分发	平台、发布者、镜像维护者	下载渠道与带宽直接影响实验能否开始	免费下载 ≠ 平台零成本，也 ≠ 永久免费
工具维护	社区贡献者、公司、研究者	提供适配、文档、bug 修复，本组是纯受益方	热度高 ≠ 对本任务适配好
推理	API 调用方，或自托管者	公开 AI 需要设预算上限，否则会被刷	开放权重 ≠ 推理免费；省了授权费不等于省了机器钱
内容与应用	组员、资料权利人、网站运营者	资料整理、核实、托管与日常维护都由组内承担	调用 API 不能替代小组自己的核实责任
访客使用	同学（提供真实问题与反馈）	浏览与问答不索取个人模型密钥	不能默认同学愿意上传个人资料

4.2　三笔账，本组目前算不清

- **训练成本**：只知道“很贵”，没有任何一份可引用的公开账单。所以本书不写具体金额，只写“由模型机构承担”。
- **推理成本**：按 token 计价，但没有真实调用记录，因而没有实测账单。这也是正文里 API 价格一律标“未核实”的原因。
- **人力成本**：最容易被忽略的一项——资料核实、每周检查、反馈处理，全是组员的时间，没有计价但真实存在。

> 一句话记住
>
> 这套生态之所以能让学生用得起，是因为**最贵的那一步被上游一次性摊掉了**。我们要付的不是训练费，而是推理费和核实的时间。

05 / 信息入口：从哪里持续拿到可靠信息

生态是会动的，所以比“知道多少”更重要的是**知道去哪儿看**。这一节给两层入口：学术入口（会议与期刊）和工程入口（模型卡、文档、发布记录）。

5.1 会议与期刊：分类口径必须写明版本

分类统一采用 **CCF 2022 版推荐目录（2023-03-08 发布）**，不写“最新目录”。CCF 官网的正式发布说明可以找到，但分类页直接读取受限，**下面每个标签在提交前仍需对着目录原件逐项复核。**

入口	与选题的关系	分类口径	怎么用
NeurIPS	模型、优化、学习方法；RAG 等论文的研究背景	CCF 2022 版 · 人工智能 A 类	从正式论文追方法与实验条件
ICML	学习理论、训练与优化	CCF 2022 版 · 人工智能 A 类	优先选与适配或评测直接相关的工作
ACL	自然语言处理、语言模型与评测	CCF 2022 版 · 人工智能 A 类	检查具体论文类别与正式发表信息
AAAI	人工智能综合研究与应用	CCF 2022 版 · 人工智能 A 类	按选题相关性筛选，不逐篇通读
ICLR	表征学习与模型适配的重要研究入口	列为领域重要会议；**此处不填未复核的 CCF 标签**	看开放评审意见，比看结论更有用
JMLR	机器学习期刊，也收部分开源软件论文	按官方期刊入口阅读，本稿不作等级判断	长文适合补方法细节
TACL	计算语言学与自然语言处理期刊	按官方期刊入口阅读，不与会议录混为一谈	关注语言任务、评测与方法

会议级别不能代替对单篇论文证据与任务相关性的判断；**arXiv 预印本也不自动等于同行评审论文。**

5.2 工程信息：分层看，别混着看

信息类型	能回答什么	不能回答什么 / 怎么核对
官方论文	方法是什么、在什么条件下成立	不回答“现在哪个版本能用”；要配模型卡看
模型卡	许可、上下文长度、训练数据、已知局限	常写得比论文乐观，遇到 “out-of-scope” 一定要读
文档与 Releases	这个版本支持什么、何时改了什么	文档常滞后于代码，两者对照看；本册版本号都取自 Releases
issue / 讨论区	别人踩过的坑、临时绕过方法	只当线索，**必须自己复现一次**才算核实
个人博客 / 公众号	入门解释、经验总结	最容易过时和夸大，只能用于建立直觉

5.3 每周固定检查 3–5 个，比泛泛追踪全领域可持续

本组盯住链上每一段的一个代表：**Qwen 的发布、PEFT 与 TRL 的 release、vLLM 与 Ollama、lm-evaluation-harness。**每周只看这四处的变更摘要，有变化才进待核实线索。

理由是：生态信息是**无穷**的，组员的时间是**有限**的。盯住交接点比盯住新闻流有用——断链永远发生在交接处。

> 一句话记住
>
> 可靠信息不是“看起来权威的网站”，而是**能回到具体版本、具体日期、具体文件的那一份。**带不上这三样的，都只能算线索。

06 / 国际合作与竞争、规则与责任

这一节讲三件最容易被说错的事。它们的共同点是：**听上去很像常识，但每一条都能举出反例。**作业要求“未证实的联系标为推断”，这三条就是最该守住的边界。

6.1 “开源”不等于“随便用”

权重能下载，只说明**获取没有门槛**，不说明**使用没有条件。**模型许可、训练数据许可、代码许可是三份不同的文件：

许可对象	管的是什么	常见误解
模型权重许可	能不能商用、能不能再分发、要不要署名	“能下载就能商用”——两回事
训练数据许可	数据本身能不能被再使用	“权重开放 = 数据开放”——通常不成立
代码许可	推理/训练代码的使用与修改	“代码开源 = 模型开源”——两个对象

所以本书在写任何“可复用”之前，都要先问一句：**可复用的是哪一个对象？**选型时也建议把这三项分开记录，缺一项就标待核实。

6.2 一次网络超时，不能证明“这个地区不可访问”

2026-10-25 的观测里，Hugging Face 请求 10.5 秒超时。它只能说明**那天、那台机器、那条网络**不通。换成校园网、换成镜像、换成第二天，结论可能完全不同——事实上同一天 hf-mirror 约 4.3 秒可达。

这条规矩对作业很重要：作业要求“国内普通网络可访问”，验收必须由**非组员用自己的设备和网络**实测，而不是由组员在一台机器上宣布“能开”。

6.3 仓库更新少，不等于这个模型系列衰退

llama-models 最近 release 是 v0.2.0（2025-04-05），仓库最后推送 2026-02-11；而 Llama 仓库本身 5.96 万星。这两个数字放在一起，只能得出“**这个仓库近期不活跃**”，不能得出“**这个系列不行了**”。

素材里曾有一条“Llama 相对衰退”的说法，本书保留它，但**明确标为待检验假设**，不写成本稿已证实的结论。要证实它，至少需要同一时间截面上的下载量、引用量、衍生模型数三项对比。

6.4 三类说法的改写对照

容易脱口而出的说法	改成有依据的说法
“Hugging Face 国内用不了”	“2026-10-25 单台网络实测 10.5 秒超时；同日 hf-mirror 约 4.3 秒可达，需换网络复测”
“Llama 已经衰退了”	“llama-models 最近 release 为 v0.2.0（2025-04-05），仓库活跃度低；是否衰退缺少跨指标证据”
“Qwen 最强”	“Qwen 有明确的官方发布、权重与 Ollama 条目，是本组唯一能走完整条链的案例”
“这个模型开源所以能商用”	“权重许可允许下载；商用条件需查该版本的许可证原文”

> 这一节的实际作用
>
> 它不只是措辞练习。作业的验收里有一条是**“事实、他人观点和团队推断分清”**——上面四组改写，就是把推断放回推断的位置。写不清楚的地方，宁可标“待核实”。

07 / 网络与访问：本组的两次实测

这一节是本书唯一带“实测”性质的部分。**不写“国内能不能访问”这种大结论**，只写哪天、哪台机器、哪个入口、多少秒。

7.1 第一次观测：2026-10-25，命令行抓取

入口	结果	耗时	备注
魔搭 ModelScope	可达	0.2–0.4 s	国内主要下载渠道
hf-mirror.com	可达	≈ 4.3 s	作为备用渠道，速度明显慢于魔搭
Hugging Face	超时	10.5 s	本次请求未完成，非永久结论
阿里云百炼（控制台）	可达	0.1 s	控制台可达 ≠ API 可用
硅基流动（官网）	可达	0.4 s	同上，需另测接口
OpenCompass	可达	0.1 s	榜单站，不是评测框架本体
LMArena	未连通	–	换网络需复核
Ollama 库	可达	–	qwen3.8 有条目

均为单台设备、单次抓取，未附完整日志。本稿**没有把它改写成更晚日期的复测结果**——这一条是数据诚实性的底线。

7.2 第二次观测：2026-10-28，准备本册时顺带复核

入口 / 用途	结果	说明
GitHub API（核对仓库与版本）	可达	本册所有星数与版本号均由此取得
raw.githubusercontent.com（取公开文件）	可达	成功下载 1.46 MB 的公开 PDF，说明大文件也能通
nlp.stanford.edu（代表实验室入口）	不可达	尝试两次均失败，故正文不建立该实验室的贡献关系

这两次观测放在一起，能看出一个很有用的对比：**同一天里，GitHub 的 API 和文件下载都通，但某个校园域名不通。**所以“某个网站打不开”根本推不出“某个地区不能访问”——它连“这个域名不行”都推不出来，只能推出“此刻我这条线路到它有困难”。

7.3 这份观察怎么用

- **准备双渠道。**主用魔搭，备用 hf-mirror，并在实验记录里写明用的是哪条。
- **区分“页面可达”和“接口可用”。**控制台 0.1 秒能开，不代表 API key 能调通、能出结果。
- **别用一次结果下大结论。**网站验收必须由非组员在真实校园网、移动网络上各测一次。
- **把时间戳写进记录。**“10.5 秒超时”离开日期就没有意义，因为网络状况一直在变。

> 一个诚实的说明
>
> 本节的观测样本量是**两次、两台次机器次**（严格说是一次单设备抓取 + 一次编辑复核），远不足以代表任何地区的普遍情况。它的价值在于**示范怎么记录**，而不是提供结论。

08 / 这五条，才是对本组真正有用的结论

前面九页都是材料。这一页给结论：如果只记五句话，记这五句。**每句后面都配一条依据，方便别人来质疑。**

结论一：复用权重 ≠ 拥有训练数据

能下载到 .safetensors，不代表知道它用什么数据训练的，也不代表那些数据可以再使用。DeepSeek 的模型仓库只有约 1.7 MB 说明与推理代码、权重另发，这件事本身就说明**“模型”被拆成了好几个可分别授权的对象。**

依据：DeepSeek 仓库核对（2026-10-25）；模型卡与许可证分离的通行做法。

结论二：调用 API ≠ 掌握模型

用百炼或硅基流动的接口，得到的是**一次服务**，不是一份能力。模型换版本、价格调整、接口下线，应用立刻受影响。所以本组把“服务提供方”单列为参与者，而不是当成工具。

依据：API 平台按 token 计价的通行模式；本组无实测账单，价格标未核实。

结论三：评测通过 ≠ 会答疑

C-Eval 测的是学科选择题。课程答疑要的是解释清楚、给得出出处、不确定时敢说不知道。通用榜单只在初筛阶段有用，**真判断要靠自建小测试集。**

依据：C-Eval 1878 星（hkust-nlp/ceval）为选择题集；作业要求“小组需建设独立测试”。

结论四：社区热度 ≠ 适配质量

Dify 15.9 万星、Open WebUI 15.7 万星，星数远高于很多关键工具。但**星数衡量的是关注度，不是它和我们这个任务的贴合度。**选工具要看：能不能接我们的检索、能不能显示引用、部署难度是否可控。

依据：各仓库星数为 2026-10-25 GitHub API 核对值。

结论五：版本号 ≠ 能力

v5.20.2 比 v0.21.2 大，但它们是两个不同的库，版本号之间没有可比性。真正要比的是**同一个库的两个版本之间改了什么**，以及**这个库和我们基座是否兼容。**

依据：Transformers v5.20.2、PEFT v0.21.2、TRL v1.16.0 各自独立演进。

8.1 这五条什么时候会失效

任何结论都有边界。下面把每条结论的“有效期”写出来，**条件一变，结论就要重写**：

结论	什么情况下不再成立
复用权重 ≠ 拥有数据	若发布方公开了完整训练数据与许可，这条就要改写
调用 API ≠ 掌握模型	若我们改为本地部署并自行微调，依赖关系就从“服务”变成“权重”
评测通过 ≠ 会答疑	若通用榜单新增了开放问答与引用质量评测，初筛价值会上升
社区热度 ≠ 适配质量	若某工具官方明确支持本组任务所需接口，热度的参考价值才提高
版本号 ≠ 能力	几乎没有例外；这条是长期成立的

如果只留一句话

生态地图的用途不是“知道有哪些项目”，而是**在选型时知道自己在依赖谁、依赖到什么程度、断了以后怎么办。**前四页的材料都服务于这一句。

09 / 还没核实的：逐条写清“怎么才算核实”

作业明确要求“尚未理解或核实的问题”要可见。所以这一页不藏拙：**七项还没落实的事，每项都写清现状和变成“已核实”的具体条件。**

项目	现在的状态	变成“已核实”需要什么
会议分类标签	按 CCF 2022 版填写，但未逐项对原件	保存一份该版人工智能分类目录（PDF 或截图）进来源目录，再把 7 个入口逐个核对打勾
代表实验室	Stanford NLP 入口两次抓取失败	在可访问网络下打开该站，找到与本组任务直接相关的项目页，再建立贡献关系；否则维持不写
候选团队	DeepSeek、Llama、智谱、月之暗面只有仓库数据，无模型卡与贡献说明	选定比较任务后，为每家在用的那个版本补模型卡、许可与一条可引用的贡献
API 价格	只有“按 token 付费”的定性描述	实际调用一次并保存账单截图；没有账单就继续标未核实
课程资料授权	课程原文与自建问答的可用范围未确认	取得教师或课程方的明确许可，或改用公开可引用的材料
理解程度自评	各节点仍为“待自评”	由组员本人对每个节点标注：已初步理解 / 已经尝试 / 待深入学习，并附一次尝试记录
非组员反馈	尚未取得	至少三名非组员用自己设备访问并给出意见，逐条记录处理结果与理由

9.1 为什么要把“没做到”写这么细

因为**把未核实写成已核实，比自己承认不知道危险得多。**一旦某个数字被当成事实引用出去，后面所有依赖它的判断都跟着错，而且很难追回来。

反过来，写清“还差什么才能核实”，本身就说明我们知道这条路怎么走完——这比一个漂亮的假结论有用。

9.2 核实之后还要做什么

核实不是终点，只是把一条线索变成一条可用的事实。之后还要走三步，否则核实完的东西很快又会过期：

- **写进来源目录**：新增一条 S 编号，注明取用日期与具体页面，而不是只写“官网”。
- **回填到节点卡片**：把“待核实”改成“已核实”，并在依据栏指向新编号，保持可追。
- **设定复查时间**：版本类信息建议一个月看一次，许可类信息一学期看一次；过期未复查的，退回“待核实”。

> 本册的三条自我约束
>
> 一、**没有新增未经核实的人名、机构、版本号**；二、**没查到原件的，一律留在待核实**；三、**由本组推出的判断，都标成推断**，不混入事实。这三条如果破了，前面十三页都要重写。

10 / 来源目录与版本记录

本册引用分两类：**S 开头是公开来源**（论文、官方文档、台账页），**L 开头是本组自己的素材**。完整目录与链接见网站「来源目录」页，这里列出本册实际用到的部分。

编号	来源	本册用于
S01	Attention Is All You Need（2017）	Transformer 作者与架构来源
S02	Retrieval-Augmented Generation（2020）	RAG 作者与思路来源
S03	LoRA（2021）	低成本适配方法来源
S04	QLoRA（2023）	量化适配与显存条件
S05	PEFT 文档（LoRA 概念指南）	适配实现与版本
S06	TRL SFTTrainer 文档	监督微调流程与版本
S07	Transformers / PEFT 集成文档	加载与集成的边界
S09	LM Evaluation Harness	评测框架与版本
S10	vLLM 文档	推理部署入口
S11	Qwen 官方发布与模型卡	主案例的证据链
S12	Stanford CS336 课程	研究型课程团队
S14	CCF 推荐国际会议与期刊目录（2022 版）	会议分类口径
S15 / S16	GitHub Pages 相关文档	静态托管与访问边界
S21	阿里云百炼模型调用价格页	按 token 计价（价格未核实）
L3	领域地图素材（组内）	课程资料与任务定义
L4	生态地图素材包（组内，赵志钰）	节点、星数、版本、可达性

10.1 版本与核对记录

日期	版本	做了什么
2026-10-25	素材包	用 GitHub API 核对仓库数、星数、版本号；命令行抓取各入口可达性
2026-10-28	本册 v1.0	重排为 15 页；补第二次网络复核（GitHub 通、Stanford NLP 不通）；补充五个卡点、五条结论与最小可用路径

本册所有星数、版本号、可达性结论均带核对日期。**离开日期的数字在生态地图里没有意义**——这是本册与普通资料汇编最大的区别。

接下来该做什么

下一步不是继续加内容，而是**把第 14 页那七项逐条落实**：先补会议分类原件与自评，再等选型确定后补模型卡与账单。内容量已经够了，缺的是证据。